P2 Sistemas Interactivos y Ubicuos

Prototipar

Sistemas Interactivos y Ubicuos
Alejandro Ladrón de Guevara Jiménez, NIA = 100499541
Mario Pérez Carranza, NIA = 100500454
Pablo Roig Sanchez, NIA = 100525980

Índice

1. Introducción **3**

2. Especificaciones técnicas del sistema **3**

3. Implementación de interacciones de gestos y voz del sistema **6**

4. Prototipado experiencial **9**

5. Errores, cambios y mejoras en las diferentes iteraciones **11**

6. Videos **13**

7. Conclusiones **14**

1. Introducción

En las presentaciones en aula y en entornos online, el control de diapositivas, funciones de apoyo e interacción con el público suele depender de teclado, ratón u otros dispositivos físicos, lo que interrumpe el ritmo natural de la exposición. Nuestro sistema busca resolver este problema mediante un sistema más ágil e intuitivo que permita controlar una presentación usando principalmente gestos y comandos de voz.

Para ello, hemos desarrollado un prototipo interactivo multidispositivo y multiusuario que distingue entre presentador y espectadores, sincronizando la información en tiempo real entre distintas pantallas. El sistema permite navegar por diapositivas, realizar zoom, dibujar sobre la presentación, generar subtítulos, lanzar encuestas y gestionar turnos de palabra, integrando además cámara y audio para mejorar la participación remota, entre otras interacciones.

Esta memoria se desarrolla a partir de lo planteado en la P1, explicando la implementación técnica del prototipo, las interacciones desarrolladas, las pruebas realizadas y las mejoras introducidas durante el proceso de prototipado.

2. Especificaciones técnicas del sistema

En esta sección describiremos los aspectos técnicos principales del sistema desarrollado. Para ello, presentaremos la arquitectura general de la aplicación, los distintos roles y dispositivos implicados, las tecnologías, bibliotecas y protocolos utilizados, y el diagrama de comunicación que muestra cómo se coordinan e intercambian información los diferentes elementos del sistema.

El sistema desarrollado tiene una arquitectura cliente-servidor orientada a la sincronización en tiempo real entre múltiples dispositivos. Se compone de un servidor central, el cual es el encargado de servir la aplicación web y coordinar el estado compartido de la presentación, y de dos tipos de clientes: el presentador y los espectadores. Las interacciones basadas en gestos y voz se procesan localmente en cada cliente mediante tecnologías web, mientras que los eventos del sistema, como el cambio de diapositivas, los subtítulos, las encuestas o los turnos de palabra, se sincronizan a través del servidor mediante Socket.IO. Además, la

comunicación de audio entre usuarios se realiza mediante WebRTC, cuya señalización se gestiona también a través del servidor.

Nuestra aplicación consta de dos roles principales: presentador y espectadores, los cuales pueden ser elegidos al iniciar el sistema.

El presentador es quien controla la exposición. Puede iniciar y detener la presentación, navegar entre diapositivas, utilizar comandos de voz, dibujar sobre la pantalla mediante gestos, activar o desactivar subtítulos automáticos, recibir notificaciones, gestionar los turnos de palabra de los espectadores y lanzar encuestas en tiempo real.

Los espectadores acceden al sistema introduciendo su nombre y, una vez iniciada la presentación, pueden seguir las diapositivas sincronizadas, levantar la mano para pedir turno de palabra y participar en las encuestas creadas por el presentador. Cuando el presentador concede el turno a un espectador, este puede activar su micrófono durante un tiempo limitado de 3 minutos. El presentador podrá manualmente inhabilitar el micrófono del espectador correspondiente cuando el quiera.

Además, ambos pueden encender/apagar la cámara y el micrófono, poner la aplicación en pantalla completa (versión de escritorio) y alternar la vista entre la presentación y una cuadrícula con los usuarios activos en la presentación.

Para el desarrollo de la aplicación se han utilizado distintas tecnologías web orientadas a la creación de sistemas interactivos en tiempo real:

Node.js se ha empleado para la ejecución JavaScript fuera del navegador y así poder construir el servidor de la aplicación, mientras que Express se ha utilizado para simplificar la configuración del servidor y la gestión de rutas. Socket.IO permite la comunicación en tiempo real entre cliente y servidor, lo que permite la sincronización de diapositivas, gestos, encuestas, turnos de palabra y demás eventos del sistema.

Para la interacción gestual se ha utilizado MediaPipe Hands, que permite detectar y procesar la posición de la mano y de los dedos a través de la cámara de forma

fluida. Para la interacción por voz se ha empleado la Web Speech API, concretamente para el reconocimiento de voz (STT, Speech to Text). Además, WebRTC se ha utilizado para la comunicación de audio en tiempo real entre usuarios. Finalmente HTML, CSS y JavaScript se han usado para construir la estructura, el diseño y la lógica de la interfaz web del sistema.

Diagrama de arquitectura y comunicación del sistema

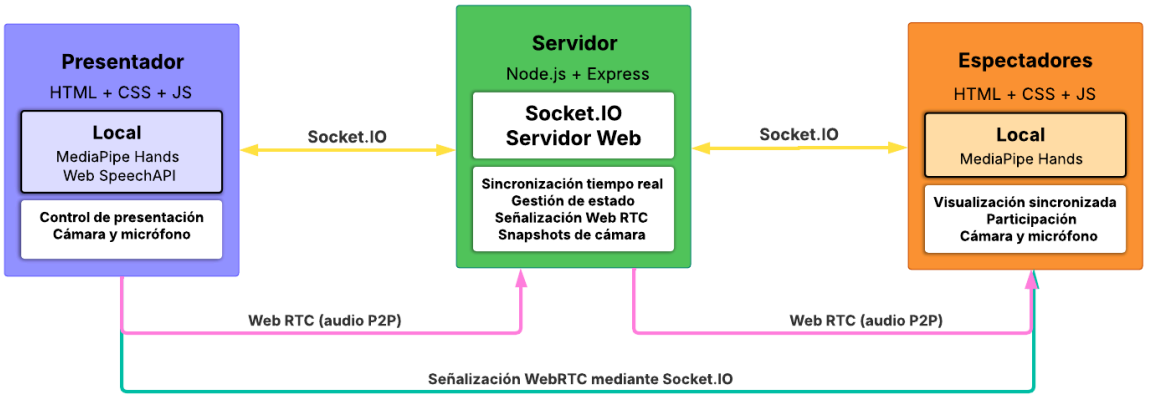

En este diagrama mostramos la arquitectura general del sistema y el flujo de comunicación entre sus tres elementos principales: el presentador, el servidor y los espectadores. Tanto el presentador como los espectadores acceden a una aplicación web desarrollada con HTML, CSS y JavaScript, mientras que el servidor, implementado con Node.js, Express y Socket.IO, se encarga de servir la aplicación y sincronizar en tiempo real el estado de la presentación, los eventos de interacción y la señalización de WebRTC. El procesamiento de gestos y voz se realiza localmente en los dispositivos cliente mediante MediaPipe Hands y Web Speech API, mientras que la transmisión de audio entre usuarios se establece mediante conexiones WebRTC peer-to-peer, cuya señalización se gestiona a través del servidor usando Socket.IO. Además, la compartición de la cámara y el video procesado por esta se realiza mediante el envío de snapshots (diferentes frames capturados periódicamente por la cámara de cada usuario) a través del servidor usando también Socket.IO.

3. Implementación de interacciones de gestos y voz del sistema

En esta sección describiremos la implementación de las principales interacciones del prototipo, combinando gestos, comandos de voz y controles visuales. Para ello, presentamos tanto las interacciones mínimas requeridas por la práctica como las funcionalidades adicionales incorporadas, explicando en cada caso su funcionamiento, su utilidad dentro del sistema y las decisiones de diseño tomadas durante su desarrollo.

Las interacciones mínimas implementadas permiten navegar por las diapositivas, iniciar o detener la presentación y finalizarla. El presentador puede avanzar o retroceder diapositivas mediante un gesto de desplazamiento lateral con el dedo índice, lo que permite cambiar el contenido sin depender de teclado o ratón. Además, la presentación puede iniciarse, detenerse o finalizarse mediante botones y comandos de voz.

Además de las funciones mínimas, se han incorporado varias interacciones adicionales que amplían las posibilidades de nuestro sistema. Entre ellas se encuentran el zoom por gestos, el dibujo sobre las diapositivas, la generación de subtítulos en tiempo real, la gestión de turnos de palabra mediante mano levantada, la creación de encuestas personalizadas, el uso de cámara y micrófono, el cambio de vistas y las notificaciones del sistema. Estas funciones se han añadido para hacer la experiencia más interactiva, mejorar la comunicación entre presentador y espectadores y adaptar el sistema a un contexto híbrido o remoto.

A continuación, describiremos las principales interacciones implementadas en nuestro sistema:

- Pantalla de inicio: Es la primera pantalla de la aplicación y permite seleccionar el rol de presentador o espectador. En el caso del espectador, es necesario introducir un nombre antes de acceder. Elegimos esta implementación por su simplicidad y porque permite identificar fácilmente a los usuarios conectados.

- Iniciar/detener presentación: El presentador puede iniciar o detener la presentación mediante un botón o mediante comandos de voz. Al iniciarse, las diapositivas pasan a mostrarse también en la pantalla de los espectadores. Además, se muestra un contador con la diapositiva actual y el total disponible.
- Cambiar diapositiva: Durante la presentación, el presentador puede avanzar o retroceder diapositivas deslizando el dedo índice hacia la izquierda o hacia la derecha. Lo elegimos ya que se trata de un gesto sencillo que permite mantener la fluidez de la exposición. Además, también puede cambiar libremente de diapositiva usando comandos de voz, lo que le añade versatilidad al sistema dependiendo de las preferencias del presentador.
- Botón de activar detección de voz: El presentador puede activar o desactivar el reconocimiento de voz mediante un botón. Esta decisión se tomó para que el sistema solo escuche comandos cuando el presentador lo desee, respetando su privacidad.
- Cámara: Con esta funcionalidad, tanto el presentador como los espectadores pueden activar o desactivar la cámara en cualquier momento.
- Micrófono: Con esta funcionalidad, tanto el presentador como los espectadores pueden activar o desactivar el micrófono en cualquier momento. Los espectadores sólo lo tendrán disponible cuando el presentador les haya dado turno de palabra.
- Zoom: El presentador puede ampliar una zona de la presentación mediante un gesto de pellizco hacia afuera. El presentador puede realizar varios aumentos del mismo punto, dependiendo de si quiere más o menos zoom. Para eliminar el zoom, se utiliza el gesto de cerrar el puño. Esta interacción permite destacar partes concretas de una diapositiva de forma rápida y natural.
- Dibujar: El presentador puede activar o desactivar el modo dibujo mediante botón o por voz. Cuando está activo, se crea una capa sobre la diapositiva que permite al presentador dibujar utilizando el gesto de apuntar con el dedo índice. Esta función resulta útil para resaltar elementos o reforzar explicaciones visualmente y se eligió este gesto ya que es intuitivo que sea el dedo índice el pincel para dibujar.

- Borrar: Todo lo dibujado puede eliminarse mediante un botón o por voz. Esto permite limpiar la diapositiva cuando deja de ser necesario seguir marcando elementos sobre ella o si se requiere hacer un nuevo dibujo.
- Subtítulos: El sistema permite activar subtítulos en tiempo real generados a partir de la voz del presentador. Pueden activarse o desactivarse por botón o por comando de voz. Esta funcionalidad mejora la accesibilidad y la comprensión del contenido expuesto.
- Pantalla completa: La aplicación puede mostrarse en pantalla completa mediante un botón, tanto en presentador como en espectadores, mejorando la visibilidad de la interfaz y de las diapositivas.
- Lanzar encuesta: El presentador puede lanzar encuestas personalizadas por voz para que los espectadores participen en tiempo real. En ellas puede elegir la pregunta y las opciones, las cuales serán registradas mediante comandos de voz individuales con tiempos de espera entre cada respuesta, para darle tiempo al presentador y que no haya errores en la creación de la encuesta. Esta función se incorporó para fomentar la interacción y hacer la presentación más dinámica.
- Vistas: Existen dos modos principales de visualización: uno centrado en la diapositiva y otro orientado a mostrar la cuadrícula de usuarios conectados. Las vistas se intercambian entre la parte central de la pantalla, donde estaría inicialmente la presentación, y la parte inferior derecha, donde estarían inicialmente las cámaras de los usuarios. El cambio entre ambas vistas se realiza mediante el botón “Intercambiar vista”. Esta decisión se inspira en plataformas de videollamadas y permite adaptar la interfaz a las necesidades de cada momento.
- Levantar la mano: Los espectadores pueden levantar la mano para pedir el turno de palabra mediante el botón o un gesto mostrando la palma de la mano hacia la cámara. Esto se hace porque los espectadores no tienen permiso para activar el micrófono de manera normal para no crear ruido innecesario durante la presentación. Es un gesto sencillo y natural para todo el mundo. Entonces, le llega un aviso al presentador de que hay un espectador con la mano levantada y mediante un botón le puede otorgar el turno de palabra durante 3 minutos. El presentador puede quitarle el acceso a hablar a los espectadores en cualquier momento.

- Notificaciones: El sistema cuenta con una sección de notificaciones que registra cuando un usuario se conecta o desconecta, cuando un espectador pide turno de palabra o cuando se crea una encuesta. Estas notificaciones sirven como mecanismo de feedback y ayudan a que los usuarios comprendan qué está ocurriendo en cada momento y tengan un registro de ello.

4. Prototipado experiencial

En esta fase realizamos distintas pruebas físicas y técnicas para comprobar cómo se comportaban las interacciones del sistema en un contexto de uso real. El objetivo fue evaluar si los gestos y comandos planteados inicialmente resultaban naturales, cómodos y suficientemente fiables, y realizar ajustes antes de considerar la implementación final del prototipo.

Para realizar las pruebas utilizamos *ngrok*, ya que nos permitió exponer el servidor local y conectar varios dispositivos al sistema de forma sencilla. Gracias a esto pudimos probar la aplicación en distintos entornos (móvil, ordenador de sobremesa y portátil) y comprobar su comportamiento en condiciones más reales.

Además, *ngrok* proporcionaba una conexión HTTPS sin necesidad de configurar certificados, lo que fue clave para poder usar correctamente funcionalidades como la cámara, el micrófono y la comunicación entre cliente y servidor. Esto nos permitió verificar tanto la sincronización entre pantallas como el funcionamiento de las interacciones de voz, gestos y audio.

A partir de las ideas definidas en la P1, comenzamos probando una serie de gestos y comandos que, en un primer momento, nos parecieron los más naturales e intuitivos para controlar la presentación sin depender de teclado o ratón. La intención era que las interacciones se asemejasen a movimientos ya conocidos por los usuarios y que pudieran ejecutarse de forma rápida durante una exposición real.

Para la función de zoom, pensamos en utilizar el gesto de pellizcar con el pulgar y el índice para ampliar una zona de la diapositiva, y el gesto inverso para reducir o

quitar el zoom. Esta idea se eligió porque se trata de una interacción muy extendida en pantallas táctiles y resultaba fácil de asociar con la acción de acercar o alejar contenido.

Para avanzar y retroceder entre diapositivas, planteamos inicialmente el gesto de desplazar la palma de la mano hacia la derecha o hacia la izquierda. Esta decisión se tomó porque parecía un movimiento simple, visible y fácil de realizar mientras el presentador estaba hablando. Además, encajaba con la idea de “mover” la presentación en una dirección concreta, como el deslizar en una pantalla de un móvil o tablet.

Para pedir el turno de palabra, probamos el gesto de mostrar la palma de la mano hacia la cámara, simulando la acción de levantar la mano que se haría de forma natural en un aula. Este gesto nos pareció adecuado desde el principio porque es una acción universal, fácil de comprender y coherente con el contexto educativo del sistema.

En el modo dibujo, la idea inicial fue utilizar el dedo índice como herramienta principal para señalar y trazar sobre la diapositiva. Pensamos que era la opción más intuitiva, ya que reproduce el gesto natural de apuntar a una zona concreta de la pantalla y permite relacionar directamente el movimiento de la mano con el trazo generado.

Tras las pruebas realizadas, observamos que no todas las interacciones planteadas inicialmente resultaban igual de eficaces o naturales en un contexto real de uso, ya sea por la incomodidad de realizarlas o porque no se detectaban correctamente. Por ello, fue necesario ajustar varios gestos y comandos hasta encontrar opciones más estables, precisas y cómodas para el usuario.

En el caso de la navegación entre diapositivas, la idea inicial de mover la palma completa hacia la izquierda o la derecha fue descartada, ya que la detección no resultaba suficientemente precisa con MediaPipe Hands y producía errores o falta de respuesta. Finalmente, optamos por utilizar el desplazamiento lateral del dedo índice, que ofrecía un reconocimiento más fiable, permitía mantener la fluidez de la presentación y era también un movimiento intuitivo y sencillo.

Para la función de zoom, mantuvimos como gesto principal el pellizco con el pulgar y el índice para ampliar la diapositiva, ya que seguía siendo la interacción más natural e intuitiva. Sin embargo, el gesto inverso para quitar el zoom no resultó tan robusto como esperábamos en las pruebas ya que interfería con su contraparte cancelando inmediatamente el zoom, por lo que finalmente decidimos sustituirlo por el gesto de cerrar el puño, al ser más claro y menos propenso a errores de detección.

En la función de dibujo, se mantuvo la idea inicial de utilizar el dedo índice para trazar sobre la diapositiva. Esta decisión se conservó porque fue una de las interacciones más naturales desde el principio, al reproducir el gesto habitual de señalar o marcar un elemento concreto en la pantalla.

Para pedir el turno de palabra, también se mantuvo el gesto de mostrar la palma abierta hacia la cámara. Esta interacción fue la que mejor se adaptó al contexto del sistema, ya que imita directamente el gesto real de levantar la mano en una clase y resultó fácil de comprender por todos los participantes.

En cuanto a los comandos de voz, también fue necesario ajustarlos durante el desarrollo para que resultaran más claros y para evitar confusiones entre órdenes similares. Especialmente con los comandos de voz de palabras con acentuaciones muy marcadas como “subtítulos”, que el sistema a veces reconocía como “subtitulos” y no actuaba. A medida que se realizaron pruebas, se añadieron variantes de activación y se ajustaron las expresiones reconocidas para mejorar la robustez del sistema ante diferentes pronunciaciones y formas de hablar.

Estas pruebas se llevaron a cabo a lo largo de varias sesiones de trabajo iterativo durante el desarrollo, cuyos hallazgos quedaron recogidos en la sección de errores y mejoras.

5. Errores, cambios y mejoras en las diferentes iteraciones

En esta sección describiremos los principales problemas técnicos encontrados durante el desarrollo del prototipo y las mejoras realizadas a partir de las pruebas iterativas. Para ello, explicaremos qué dificultades surgieron en la implementación,

cómo afectaban al funcionamiento del sistema y qué decisiones se tomaron para corregirlas o adaptar la solución respecto a la idea inicial planteada en la P1.

A continuación, nombraremos y explicaremos los distintos obstáculos que nos hemos encontrado en el desarrollo de nuestro sistema y cómo los hemos afrontado:

- Sincronización inicial de espectadores.
  Los espectadores no veían bien la presentación al entrar hasta refrescar. Se resolvió forzando la petición del estado actual al conectarse y reenviando el estado compartido desde servidor.
- Gestión de cola de voz.
  El reconocimiento iba acumulando comandos previos y podía repetir acciones antiguas. Se corrigió procesando solo fragmentos nuevos, borrando los antiguos y reajustando la lógica de interpretación.
- Zoom por gesto.
  El gesto inicial de zoom y su cancelación daban falsos positivos o se interferían entre sí. Se ajustó la sensibilidad y se acabó adoptando pellizco para ampliar y puño para quitar el zoom completo.
- Navegación por diapositivas.
  El gesto con palma completa no era fiable con MediaPipe Hands. Se sustituyó por el deslizamiento lateral del dedo índice que era también muy intuitivo, cómodo y sencillo de realizar.
- Turnos de palabra.
  Al principio la acción de permitir turno de palabra no notificaba bien al espectador o no actualizaba correctamente el estado. Se corrigió guardando el estado en servidor, notificando al usuario y permitiendo además retirar el turno manualmente, con un máximo de 3 minutos de habla si este no se retiraba antes.
- Múltiples encuestas.
  Tras cerrar una encuesta, las siguientes no siempre se lanzaban bien. Se reorganizó el reinicio del estado interno de encuesta y el flujo de captura de opciones por voz.
- Reconocimiento de voz en encuestas.
  Al crear una encuesta y nombrar sus opciones, el sistema no identificaba bien

cada una de ellas, solapándolas entre sí o no reconociéndolas correctamente. Para arreglarlo se creó una ventana de espera entre cada una de las opciones para que al presentador le diese tiempo a nombrarlas por separado, añadiendolas una a una a la preview de encuesta que va mostrando el proceso de creación de la encuesta.

- Cámaras por snapshots.
  El vídeo no se transmitía como streaming continuo real, sino mediante snapshots enviados por Socket.IO. Se mantuvo esta solución por ser suficiente para un prototipo funcional, aunque con limitaciones de fluidez.
- Audio y cámara desacoplados.
  Al apagar la cámara el audio podía dejar de funcionar. Se corrigió separando mejor el control de pistas de audio y vídeo y forzando la resincronización cuando era necesario.
- Responsive móvil.
  Las interfaces iniciales no se adaptaban bien a pantallas pequeñas. Se añadieron reglas responsive para móviles en vertical y horizontal, priorizando especialmente la experiencia del espectador.

Todos estos cambios muestran que, aunque la idea inicial definida en la P1 sirvió como base del sistema, durante el desarrollo tuvimos que adaptar varias decisiones de interacción e implementación para conseguir un prototipo más eficiente y estable. Estos problemas fueron identificados a lo largo de varias sesiones de prototipado iterativo realizadas durante el desarrollo. En cada sesión, cada miembro del equipo implementaba nuevas funcionalidades, las probaba en el sistema real desde distintos dispositivos y registraba los fallos observados. Las correcciones se integraban posteriormente en la versión compartida del proyecto mediante una gestión coordinada del código entre los miembros del grupo. Este ciclo de implementar, probar y corregir se repitió de forma continua a lo largo del proceso, siendo la principal vía a través de la cual se detectaron y resolvieron los problemas descritos anteriormente.

6. Videos

En esta sección se recogen los vídeos que documentan los distintos escenarios de uso del prototipo. En ellos se simula el contexto de una presentación, con la participación de un presentador y varios espectadores, mostrando el funcionamiento del sistema en una situación realista.

A lo largo del vídeo se ponen en práctica todos los gestos, movimientos corporales y comandos de voz implementados, permitiendo observar cómo se desarrollaría toda la acción de la presentación.

El video se encuentra en esta carpeta de Google Drive: https://drive.google.com/drive/folders/1KUNcMWuAEjUwPajoMHGArCrkseFHFw7_?usp=drive_link

Como se puede observar en el vídeo, la aplicación proporciona varias funcionalidades orientadas a mejorar la experiencia de presentación en entornos educativos, tanto presenciales como telemáticos.

Aunque la mayoría de las interacciones se ejecutan correctamente, el sistema presenta limitaciones propias del reconocimiento de voz y gestos. Factores como la iluminación, el ruido ambiental o imprecisiones en la ejecución pueden provocar fallos puntuales en la interpretación de las órdenes.

Estos aspectos reflejan las dificultades inherentes a este tipo de sistemas y justifican la necesidad de iteración y mejora en futuras fases del proyecto.

7. Conclusiones

El desarrollo de esta práctica de prototipado nos ha permitido comprender mejor el funcionamiento de tecnologías con las que no estábamos muy familiarizados, como son Node.js, Express, Socket.IO, MediaPipe Hands, Web Speech API y WebRTC, así como su integración dentro de una misma aplicación web interactiva. Además, hemos trabajado con mecanismos de entrada como la cámara y el micrófono, y con un sistema distribuido en el que varios usuarios interactúan en tiempo real desde diferentes dispositivos.

Al mismo tiempo, hemos podido comprobar las limitaciones de estas tecnologías. La detección gestual no siempre es igual de robusta en todos los entornos o dispositivos, ya sea por la calidad de ejecución de los gestos, las condiciones de iluminación o la propia cámara. Por otro lado, el reconocimiento de voz puede verse afectado por la pronunciación o el ruido, y la transmisión mediante snapshots no ofrece la misma fluidez que una solución de vídeo en tiempo real completa. En cuanto a la interfaz responsive, la adaptación a móviles ha requerido ajustes específicos, optimizando algunas vistas mejor que otras.

De cara a la P3, estas limitaciones marcan los aspectos a validar con usuarios reales: comprobar si los gestos son comprensibles para personas externas al desarrollo, si el reconocimiento de voz es suficientemente robusto en entornos con ruido, como un aula, y si la experiencia en dispositivos móviles es adecuada para el rol de espectador.

En general, estamos satisfechos con el trabajo realizado, ya que el prototipo cumple los objetivos principales de la práctica y refleja de forma coherente la idea planteada en la P1.

8. Uso de IA

Para la realización de esta práctica hemos utilizado herramientas de inteligencia artificial generativa, principalmente Claude y ChatGPT Codex en VS Code. Se han empleado como apoyo para la comprensión de tecnologías y APIs con las que el equipo no tenía experiencia previa, como WebRTC o determinadas funcionalidades de MediaPipe Hands y Web Speech API, así como para resolver dudas técnicas concretas, identificar errores durante la depuración y revisar fragmentos de código.

Todas las decisiones sobre la arquitectura del sistema, las interacciones implementadas, los gestos y comandos elegidos y los cambios realizados durante el proceso han sido tomadas y justificadas por el grupo, a partir de lo definido en la P1 y de las observaciones recogidas durante el prototipado. El uso de IA ha servido como apoyo al aprendizaje y al desarrollo, siempre bajo supervisión del equipo, y no como sustituto de su criterio.